Mach-O文件的全称是Mach Object File Format,类似于Windows上的exe文件, Linux上的ELF文件,macOS/iOS系统中可执行文件、动态库、共享库格式都是Mach-O。

先说一个容易产生困惑的点,Mach-O和Mac没有什么关系。Mac是苹果电脑 Macintosh的简称,而Mach是一种操作系统微内核,苹果公司的设备上操作系统内 核使用的是Mach。在Mach内核中,一种可执行文件格式是Mach-O。所以不要被 Mach-O和Mac相似的名字迷惑了,实际上两者的关系不大。

在介绍Mach-O文件格式之前,首先了解一下通用二进制格式。

通用二进制格式

无论是PC还是手机,发展至今都经过了不同的CPU架构。日常项目中也经常会用到 和架构相关的问题,如

invalid armv7.....

先看一下不同平台的CPU架构。

移动平台CPU架构

手机上的CPU架构主要有armv7,armv7s,arm64。具体如下:

- 1. 从iPhone5s及以后的所有机型,其CPU架构都是arm64的。
- 2. iPhone5、iPhone5C, 其CPU架构都是armv7s。
- 3. iPhone4s以及之前的机型,其CPU架构都是armv7的。

PC平台CPU架构

i386针对的是32位的CPU处理器。x86_64是针对x86架构的64位处理器。

通用二进制格式

通用二进制格式(Universal Binary),又称为胖二进制(Fat Binary)。通用二进制文件实际上就是将支持不同CPU架构的二进制文件打包成一个文件,系统在加载运行时,会根据通用二进制文件中提供的架构,选择和当前系统匹配的二进制文件。因此,很多人认为,将通用二进制文件称为胖二进制文件更为合适。

mac OS中自带了很多的通用二进制文件,使用file命令可以查看这些通用二进制文件的信息,比如使用file命令查看python的信息:

```
file /Users/.../Desktop/python
/Desktop/python: Mach-O universal binary with 2 architectures:
[x86_64:Mach-O 64-bit executable x86_64] [i386:Mach-O executable i386]
/Desktop/python (for architecture x86_64): Mach-O 64-bit executable x86_64
/Desktop/python (for architecture i386): Mach-O executable i386
```

可以看到,python通用二进制文件包含两种架构的Mach-O文件,分别是x86_64架构和i386架构。

看一下代码中是如何定义通用二进制文件的,在/usr/include/mach-o目录下有通用二进制相关的文件。在fat.h中可以看到通用二进制文件头部结构fat_header的定义(从文件名的角度来看,通用二进制文件称为胖二进制文件也更为合适):

magic是一个固定的值,值是0xcafebabe或0xbebafeca,表示这是一个通用二进制文件;

nfat_arch表示的是该通用二进制文件包含多少个架构文件(也就是Mach-O文件)。

在fat header之后紧跟着的是多个fat arch结构体. fat arch的定义如下:

```
struct fat_arch_64 {
    cpu_type_t cputype; /* cpu specifier (int) */
    cpu_subtype_t cpusubtype; /* machine specifier (int) */
    uint64_t offset; /* file offset to this object file */
    uint64_t size; /* size of this object file */
    uint32_t align; /* alignment as a power of 2 */
    uint32_t reserved; /* reserved */
};
```

其中: cputype指定了cpu的类型

cpusubtype指定了cpu的子类型

offset指定了该架构数据相对于文件开头的偏移量

size指定了该架构数据的大小

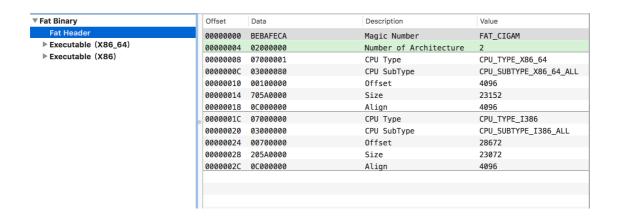
align指定了数据的内存对齐边界,值必须是2的次方

reserved是保留字段,只有64位架构的有,32位架构的无此字段。

cputype的部分取值有:

cpusubtype的部分取值有:

使用MachOview软件看一下python的信息:



可以清楚的看到,Fat Header里面的内容:

首先是fat_header,包含两种架构,后面跟着两个fat_arch结构。从图中可以看到,Fat Header之后就是两个Executable文件,也就是可执行文件,也就是Mach-O文件。

Mach-O文件

Mach-O是mac OS系统可执行文件的格式,平时用到的可执行文件,动态库,静态库,Dsym文件,都是Mach-O格式的文件。

看一下苹果官方文档中对Mach-O文件的介绍:

Header

Load commands

Segment command 1

Segment command 2

Data

Data

Section 1 data
Section 2 data
Section 3 data
Section 4 data
Section 5 data
Section 5 data
Section n data

Figure 1 Mach-O file format basic structure

可以看到,一个Mach-O文件包含三部分: Header、Load commands、Data。实际上,除了上述三部分意外,还有Loader info链接信息及一些其他的数据。

从图中可以看到,Load commands中的数据和Data中的数据是有对应关系的。具体是如何对应的,下面会介绍。

Header

Mach-O头部,描述了Mach-O的cpu类型,文件类型以及加载命令大小、条数等信息。还是使用MachOview看一下python可执行文件中的Mach-O文件:



通过MachOview可以得到Mach-O header中包含的信息,包含了Magic Number、Cpu type、Cpu subtype、file type等。看一下代码中对于Mach-O header的定义,相关的代码在mach-o/loader。h中:

```
struct mach header 64 {
   uint32_t
               magic;
                         /* mach magic number identifier */
    cpu_type_t cputype;
                          /* cpu specifier */
    cpu_subtype_t cpusubtype; /* machine specifier */
   uint32 t
              filetype; /* type of file */
   uint32 t
                          /* number of load commands */
               ncmds:
   uint32 t sizeofcmds; /* the size of all the load commands */
    uint32_t
              flags;
                         /* flags */
   uint32_t reserved; /* reserved */
};
/* Constant for the magic field of the mach_header_64 (64-bit
architectures) */
#define MH_MAGIC_64 Oxfeedfacf /* the 64-bit mach magic number */
#define MH_CIGAM_64 0xcffaedfe /* NXSwapInt(MH_MAGIC_64) */
```

magic字段是一个固定的值,为0xfeedfacf或者0xcffaedfe,表示的是这是一个Mach-O格式的文件。

cpu_type_t 和 cpu_subtype_t和上文中提到的一样,这里不再介绍。

filetype表示Mach-O文件的具体类型,它的部分取值如下:

```
#define MH_OBJECT 0x1  /* relocatable object file */
#define MH_EXECUTE 0x2  /* demand paged executable file */
#define MH_PRELOAD 0x5  /* preloaded executable file */
#define MH_DYLIB 0x6  /* dynamically bound shared library */
#define MH_DYLINKER 0x7  /* dynamic link editor */
#define MH_BUNDLE 0x8  /* dynamically bound bundle file */
#define MH_DSYM 0xa  /* companion file with only debug
sections */
```

这里python的Mach-O文件类型是MH_EXECUTE,如果我们查看的是Dsym文件,则文件类型是MH_DSYM。

ncmds 表示的是Mach-O文件中加载命令的数量。

sizeofcmds 表示的是Mach-O文件加载命令的大小。

flags 表示文件标志。

reserved 是保留字段、64位cpu架构特有。

Mach-O文件头除了提供一些格式信息外,还为加载命令提供信息。ncmds 和 sizeofcmds 在加载过程中会比较有用。

Load commands

Mach-O Header之后就是Load commands,也就是加载命令。加载命令的作用是,在Mach-O文件被加载到内存时,加载命令告诉内核加载器或者动态链接器如何调用。

可执行文件运行之后会生成一个进程,进程实际上就是特殊文件在内存中加载得到的结果,这种文件必须使用操作系统可以认知的格式,这样才对该文件引入依赖库,初始化运行环境以及顺利的执行创造了条件。在该过程中,就会用到Load command。

还是先使用MachOview看一下Mach-O文件中的加载命令:

▼ Executable (X86_64)	Offset	Data	Description	Value
Mach64 Header ▼ Load Commands	00001020	00000019	Command	LC_SEGMENT_64
LC_SEGMENT_64 (PAGEZERO)	00001024	00000048 5F5F504147455A45524F000	Command Size Segment Name	72 PAGEZERO
LC_SEGMENT_64 (_TEXT)	00001028	0000000000000000	VM Address	0
► LC_SEGMENT_64 (DATA) LC_SEGMENT_64 (LINKEDIT)	00001040	000000100000000	VM Size	4294967296
LC_DYLD_INFO_ONLY	00001048 00001050	0000000000000000	File Offset File Size	0
LC_SYMTAB LC_DYSYMTAB LC_LOAD_DYLINKER LC_UUID	00001058	00000000	Maximum VM Protection	V
			00000000	VM_PROT_NONE
	0000105C	00000000	Initial VM Protection 00000000	VM PROT NONE
LC_VERSION_MIN_MACOSX	00001060	00000000	Number of Sections	0
LC_SOURCE_VERSION LC_MAIN	00001064	00000000	Flags	
LC_LOAD_DYLIB (.Python)				
LC_LOAD_DYLIB (libSystem.B.dyli				
LC_LOAD_DYLIB (CoreFoundation)				

可以看到,Mach-O文件中有多条加载命令,加载命令的前两个字段分别是Command和Command Size。load command的数据结构定义如下:

cmdsize字段表示当前加载命令的大小。

cmd字段代表当前加载命令的类型,加载命令的类型不同,结构体就不同。对于不同类型的加载命令,他们都会在load_command结构体后面加上一个或者多个字段来表示自己特定的结构体信息。加载命令的类型比较多,其部分取值如下:

```
#define LC_SEGMENT 0x1 /* segment of this file to be mapped */
#define LC_THREAD 0x4 /* thread */
#define LC_UNIXTHREAD 0x5 /* unix thread (includes a stack) */
#define LC_PREPAGE 0xa /* prepage command (internal use)
*/
#define LC_DYSYMTAB 0xb /* dynamic link-edit symbol table info */
#define LC_LOAD_DYLIB 0xc /* load a dynamically linked shared
library */
#define LC_CODE_SIGNATURE 0xld /* local of code signature */
.....
```

下面介绍一些常见的commands。

LC_MAIN

表示main函数在Mach-O文件中的偏移

LC_UUID

确定文件的唯一标识,crash解析中也会有这个,去检测dsym文件和crash文件是否 匹配

LC_LOAD_DYLINKER

指定动态链接器linker的路径,通常为

/usr/lib/dyld

LC_LOAD_DYLIB

描述当前Mach-O文件需要哪些动态库

LC_DYLD_INFO_ONLY && LC_DYLD_INFO

这两个命令主要是给动态链接器 dyld 做 link 使用的。动态 linker 的主要作用是二进制加载到内存后,将动态链接库的信息链接起来。

该命令对应的结构体是:

```
struct dyld info command {
                    /* LC_DYLD_INFO or LC_DYLD_INFO_ONLY */
   uint32 t
              cmd;
   uint32_t
              cmdsize; /* sizeof(struct dyld_info_command) */
              rebase_off; /* file offset to rebase info */
   uint32 t
   uint32 t
              rebase_size; /* size of rebase info
   uint32 t
              bind off; /* file offset to binding info */
   uint32_t
              bind_size; /* size of binding info */
   uint32_t
              weak_bind_off; /* file offset to weak binding info
*/
   uint32 t weak bind size; /* size of weak binding info */
   uint32_t lazy_bind_off; /* file offset to lazy binding info
   uint32_t lazy_bind_size; /* size of lazy binding infs */
   uint32_t
              export_off; /* file offset to lazy binding info */
   uint32 t export size; /* size of lazy binding infs */
};
```

- 1. rebase 地址重定位
- 2. bind 地址绑定,找到使用的外部符号信息
- 3. weak bind 弱引用绑定, C++ 程序需要的
- 4. lazy bind 地址懒绑定,延迟绑定,有的外部函数,不需要在加载时就完成地址 绑定,可以在运行到的时候再去查找外部函数地址
- 5. export 要导出的函数信息

LC SYMTAB

符号表。命令对应的结构体是:

- 1. symoff 符号表在 MachO 文件中的偏移
- 2. nsyms 符号数量
- 3. stroff 字符串表在 MachO 文件中的偏移
- 4. strsize 字符串表大小

LC CODE SIGNATURE

应用签名相关信息。

LC_SEGMENT_64

表示的是将64位的段映射到进程的地址空间。可以看一下段加载命令的数据结构:

```
struct segment_command_64 { /* for 64-bit architectures */
   uint32_t cmd; /* LC_SEGMENT_64 */
   uint32_t cmdsize;
                        /* includes sizeof section_64 structs
*/
           segname[16]; /* segment name */
   char
   uint64_t vmaddr; /* memory address of this segment */
   uint64 t     vmsize;
                        /* memory size of this segment */
             fileoff; /* file offset of this segment */
   uint64_t
   uint64_t filesize; /* amount to map from the file */
   vm_prot_t maxprot; /* maximum VM protection */
   vm_prot_t initprot; /* initial VM protection */
   uint32_t nsects; /* number of sections in segment */
   uint32_t
             flags;
                        /* flags */
};
```

cmd 和 cmdsize上面已经介绍过了,不再重复。

segname字段表示的是该segment的名称。

vmaddr字段表示段的虚拟内存地址。

vmsize字段表示段所占的虚拟内存的大小。

fileoff字段表示段数据在文件中的偏移。

filesize字段表示段数据的实际大小。

maxprot字段表示页面所需要的最高内存保护。

initprot字段表示页面初始的内存保护。

nsects字段表示该segment包含了多少个section(节区),一个段可以包含0个或者多个section。

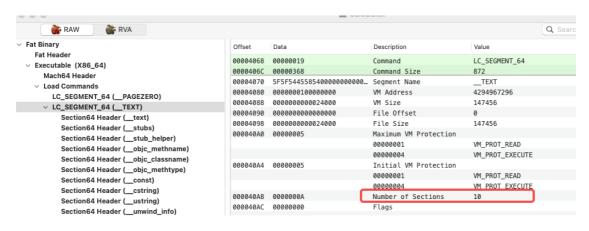
flags字段是段的标志信息。

加载命令中有fileoff、filesize、VM Adress、VM Size几个字段。表示的是将offset 处加载filesize大小到虚拟内存VM Adress开始的地方,占用的虚拟内存大小是VM Size。

Segment

上面多次提到了Segment,Segment可以翻译为段。Segment可以理解成是编译器将权限相同的多个Section合并后形成的Section集合,就是段。每一个段的权限相同,或者说,编译时候,编译器把权限相同的数据放在一起,成为段(segment)。一个段可以有0个或者多个section组成。

如下图, __TEXT Segment包含10个section。



介绍一下常见的Segment。

_PAGEZERO

_PAGEZERO段用于存储空指针,不具有访问权限。因此上述几个字段都是0。 _PAGEZERO一般为Mach-O可执行文件的第一个Segment

__TEXT

```
__TEXT segment 包含可执行代码块和只读数据,代码和只读数据在映射后都不具备内存写属性。__TEXT 中可以包含多 section,比如 __text, __cstring, __picsymbol_stub, __symbol_stub, __const, __literal4, __literal8
__DATA
```

```
__DATA segment 包含写属性的数据,也常包含多个 section,比如 __data, __la_symbol_ptr, __nl_symbol_ptr, __dyld, __const, __mod_init_func, __mod_term_func, __bss, __common
```

__LINKEDIT

链接段包含了一些符号表、间接符号表、rebase操作码、绑定操作码、导出符号、函数启动信息、数据表、代码签名、字符串表等数据。该加载命令下没有Section,需要配合LC_SYMTAB来解析symbol table和string table。

section

来简单看一下section的数据结构:

```
struct section_64 { /* for 64-bit architectures */
              sectname[16]; /* name of this section */
   char
   char
              segname[16];
                            /* segment this section goes in */
   uint64_t addr; /* memory address of this section */
   uint64 t size;
                        /* size in bytes of this section */
   uint32_t offset;
                        /* file offset of this section */
                        /* section alignment (power of 2) */
   uint32_t align;
                        /* file offset of relocation entries */
   uint32_t
             reloff;
   uint32_t nreloc;
                        /* number of relocation entries */
   uint32 t
             flags; /* flags (section type and
attributes)*/
   uint32 t
             reserved1; /* reserved (for offset or index) */
              reserved2; /* reserved (for count or sizeof) */
   uint32_t
             reserved3; /* reserved */
   uint32 t
};
```

sectname字段表示该section的name。section名都是小写字母,如__text, __data,__cstring等。

segname字段表示该section所属的segment的segmentName。

addr字段表示该section的内存起始地址。

size字段表示该section的大小。

offset字段表示该section相对文件的偏移量。

align字段表示字节区的内存对齐边界。

reloff表示重定位信息的文件偏移。

nreloc表示重定位条目的数目。

flags是section的一些标志属性。

使用MachOview看一下Section的信息:

Fat Binary	Offset	Data	Description	Value
Fat Header	00001288	5F5F6E6C5F73796D626F6C5	Section Name	nl symbol ptr
▼ Executable (X86_64)	00001298	5F5F444154410000000000000	Segment Name	DATA
Mach64 Header	000012A8	0000000100002000	Address	4294975488
▼ Load Commands	000012B0	000000000000000000000000000000000000000	Size	16
LC_SEGMENT_64 (PAGEZERO)	000012B8	00002000	Offset	8192
► LC_SEGMENT_64 (TEXT)	000012BC	00000003	Alignment	8
▼ LC_SEGMENT_64 (DATA)	000012C0	0000000	Relocations Offset	0
Section64 Header (nl_symbol	000012C4	00000000	Number of Relocations	0
Section64 Header (got)	000012C8	00000006	Flags	
Section64 Header (la_symbol			00000006	S NON LAZY SYMBOL POIN
Section64 Header (data)	000012CC	00000014	Indirect Sym Index	20
LC_SEGMENT_64 (LINKEDIT)	000012D0	00000000	Reserved2	0
LC_DYLD_INFO_ONLY	000012D4	00000000	Reserved3	0
LC_SYMTAB				
LC_DYSYMTAB				
LC_LOAD_DYLINKER				
LC_UUID				

这是Mach-O文件中某个Section的信息,和section的数据结构是一一对应的。

介绍一下常见的section,前面是Segment名称,后面是section名称。注意: Segment名称都是大写,section名称都是小写。

__TEXT.__text

主程序代码

__TEXT.__cstring

C语言字符串

__TEXT.__const

const 关键字修饰的常量

```
__TEXT.__stubs
用于 Stub 的占位代码, 很多地方称之为桩代码。
__TEXT.__stubs_helper
当 Stub 无法找到真正的符号地址后的最终指向
__TEXT.__objc_methname
Objective-C 方法名称
__TEXT.__objc_methtype
Objective-C 方法类型
__TEXT.__objc_classname
Objective-C 类名称
__DATA.__data
初始化过的可变数据
__DATA.__la_symbol_ptr
lazy binding 的指针表,表中的指针一开始都指向 __stub_helper
__DATA.nl_symbol_ptr
非 lazy binding 的指针表,每个表项中的指针都指向一个在装载过程中,被动态链
机器搜索完成的符号
__DATA.__const
没有初始化过的常量
__DATA.__cfstring
程序中使用的 Core Foundation 字符串(CFStringRefs)
__DATA.__bss
```

BSS, 存放为初始化的全局变量, 即常说的静态内存分配

__DATA.__common

没有初始化过的符号声明

__DATA.__objc_classlist

Objective-C 类列表

__DATA.__objc_protolist

Objective-C 原型

__DATA.__objc_imginfo

Objective-C 镜像信息

__DATA.__objc_selfrefs

Objective-C self 引用

__DATA.__objc_protorefs

Objective-C 原型引用

__DATA.__objc_superrefs

Objective-C 超类引用

Data

Mach-O中Load Commands之后的就是Data数据。每个段的数据都保存在这里,这里存放了具体的数据与代码。使用MachOView看一下Data:



上图红框中的就是Data部分。

开头说了,Load Commands和Data中的数据有对应关系。具体来说,一个commands对应一块数据。如下:

__TEXT Segment包含10个Section,

```
    Load Commands

      LC_SEGMENT_64 (__PAGEZERO)
  V LC_SEGMENT_64 (__TEXT)
        Section64 Header (__text)
        Section64 Header (__stubs)
        Section64 Header (__stub_helper)
        Section64 Header (__objc_methname)
        Section64 Header (__objc_classname)
        Section64 Header (__objc_methtype)
        Section64 Header (__const)
        Section64 Header (__cstring)
        Section64 Header (__ustring)
        Section64 Header (__unwind_info)
这10个Section对应的数据是:
   > Section64 (__TEXT,__text)
   > Section64 (__TEXT,__stubs)
   > Section64 (__TEXT,__stub_helper)
   > Section64 (__TEXT,__objc_methname)
   > Section64 (__TEXT,__objc_classname)
   > Section64 (__TEXT,__objc_methtype)
     Section64 (__TEXT,__const)
   > Section64 (__TEXT,__cstring)
     Section64 (__TEXT,__ustring)
     Section64 (__TEXT,__unwind_info)
__DATA_CONST Segment包含7个Section,

    Load Commands

     LC_SEGMENT_64 (__PAGEZERO)
 > LC_SEGMENT_64 (__TEXT)
  LC_SEGMENT_64 (__DATA_CONST)
       Section64 Header (__got)
        Section64 Header (__const)
       Section64 Header (__cfstring)
        Section64 Header (__objc_classlist)
       Section64 Header (__objc_catlist)
       Section64 Header (__objc_protolist)
        Section64 Header (__objc_imageinfo)
```

这7个Section对应的数据是:

>	Section64 (DATA_CONST,got)
	Section64 (DATA_CONST,const)
>	Section64 (DATA_CONST,cfstring)
	Section64 (DATA_CONST,objc_classlist)
	Section64 (DATA_CONST,objc_catlist)
	Section64 (DATA_CONST,objc_protolist)
	Section64 (DATA_CONST,objc_imageinfo)

Loader info链接信息

链接信息包含了动态加载信息 Dynamic Loader Info、函数起始地址表、符号表、动态符号表、字符串表等信息,如下所示:

- > Dynamic Loader Info
- > Function Starts
- > Data in Code Entries
- > Symbol Table
- > Dynamic Symbol Table String Table

一些问题

指令和数据分开

Mach-O文件中,命令和数据是分开的,为何要这样设计?这样设计有三个好处:

- 1. 数据和指令可以被映射到两个不同的虚拟内存区域。数据区域是可读写的,指令区域是只读的。分开存可以很方便的设置两个区域的权限。
- 2. 两个区域分离,提高了程序的局部性,有助于提高缓存的命中率。解释一下,就是段越小,功能越单一,越有助于提供缓存命中率。相反如果是很大的段,那么有一模一样段的可能性非常小,缓存命中率也就更低。
- 3. 系统运行该程序的多个副本时,指令是一样的。那么内存只需要保存一份指令,只生成几份数据就可以,能够节省内存。

Segment和section

Segment中可以包含多个section,为何要设计这样的结构?

部分的Segment,主要是__TEXT和__DATA,可以进一步分解为Section。之所以按照Segment->Section的结构组织方式,是因为在同一个Segment下的section,可以控制相同权限,也可以不严格按照Page的大小进行内存对齐,节省内存空间。而Segment对外整体暴露,在程序载入阶段映射成一个完整的虚拟内存,更好的做到内存对齐。